

Регистрация событий на видеозаписи

Материал для защиты: модель, слои, обучение, метрики и интерпретация результатов

Документ объясняет, что реализовано в проекте, почему выбрана архитектура R3D-18, как работают слои 3D-CNN, как выполняется обучение и как честно интерпретировать качество модели.

Параметр	Значение
Задача	регистрация действий как временных событий в длинном видео
Финальная модель	R3D-18 / 3D ResNet-18
Экспериментальная модель	X3D-S
Классы	stand, walk, run, jump, push_ups, squat, bend, other
Данные	82 видео, 716 размеченных событий
Финальный результат R3D-18	test F1 = 0.8421, mean IoU = 0.6658

1. Постановка задачи

Цель проекта — построить систему, которая анализирует видеозапись одного человека и регистрирует действия не как одну метку на весь ролик, а как набор временных событий: `label`, `start_sec`, `end_sec`, `avg_confidence` и `max_confidence`.

Это сложнее обычной классификации видео. Модель должна не только понять, какое действие выполняется, но и определить, где оно начинается и заканчивается. Поэтому проект состоит не только из нейросети, а из полного pipeline: проверка данных, обучение, sliding-window inference, сглаживание, EventRegistry, экспорт событий, визуализация и Streamlit-демо.

Классы проекта

- `stand` — стойка
- `walk` — ходьба
- `run` — бег
- `jump` — прыжки
- `push_ups` — отжимания
- `squat` — приседания
- `bend` — наклоны
- `other` — прочие движения

Формат результата

Поле	Смысл
<code>label</code>	название найденного действия
<code>start_sec</code>	время начала события в секундах
<code>end_sec</code>	время окончания события
<code>avg_confidence</code>	средняя уверенность модели внутри события
<code>max_confidence</code>	максимальная уверенность модели внутри события
<code>repetition_count</code>	количество повторений для периодических действий, если счетчик доступен

2. Данные и split

Финальная версия проекта обучалась на локальном пользовательском датасете: 82 видео и 716 размеченных событий.

Split	Видео	Событий	Назначение
<code>train</code>	57	489	обучение модели
<code>val</code>	12	107	подбор параметров обучения и <code>threshold</code>
<code>test</code>	13	120	финальная оценка качества

Разделение выполнено по исходным видео, а не по отдельным клипам. Это принципиально важно: если бы фрагменты одного и того же видео попали и в `train`, и в `test`, качество было бы завышено

из-за leakage.

Прямой leakage между train/val/test не обнаружен: одно и то же видео не попадает в разные split. Ограничение остается другое: видео сняты в похожих условиях, поэтому для production-оценки нужен дополнительный holdout с новыми людьми, фонами и ракурсами.

3. Финальная модель: R3D-18

Финальная модель проекта — R3D-18, то есть 3D ResNet-18 для видео. Это 3D-CNN, которая анализирует не один кадр, а короткий фрагмент видео. В проекте модель получает тензор вида [B, C, T, H, W].

Параметр	Значение	Почему это важно
B	batch size	сколько клипов обрабатывается за один шаг
C	3	RGB-каналы изображения
T	16 кадров	короткий временной контекст движения
H, W	112 x 112	размер кадра после letterbox preprocessing
frame_stride	2	кадры берутся через один, чтобы расширить временной контекст

Почему 3D-CNN

Обычная 2D-CNN видит только один кадр и хорошо извлекает пространственные признаки: контуры, форму, положение человека. Но действия отличаются не только позой, а движением во времени. 3D-свертки анализируют сразу три измерения: time, height и width.

Например, stand и walk могут выглядеть похоже на отдельном кадре, но отличаются динамикой ног. Squat и bend могут быть похожи в нижней фазе, но squat имеет характерное движение корпуса вниз-вверх. Поэтому 3D-CNN лучше подходит для регистрации действий на видео.

4. Какие слои есть в модели и что они делают

Упрощенная архитектура R3D-18 выглядит так:

Блок	Что делает	Роль в проекте
Conv3D	ищет пространственно-временные признаки	видит движение рук, ног, корпуса
BatchNorm3D	нормализует активации	стабилизирует обучение на небольшом датасете
ReLU	добавляет нелинейность	позволяет учить сложные паттерны действий
MaxPool3D	уменьшает размер признаков	снижает вычисления и повышает устойчивость к смещению
Residual blocks	учат признаки с skip connections	позволяют строить глубокую модель без деградации
Global Average Pooling	сжимает feature maps в вектор	оставляет смысл признаков всего клипа

Linear classifier	выдает logits по 8 классам	адаптирует pretrained модель под задачу проекта
-------------------	----------------------------	---

Conv3D

Conv3D — ключевой слой для видео. Он работает не только по высоте и ширине кадра, но и по времени. Такой слой может найти паттерны: рука поднялась, корпус наклонился, человек движется вперед, ноги меняют положение, тело движется вверх-вниз.

В проекте это важно для различения walk/run, squat/bend, stand/walk и push_ups/other. На одном кадре эти действия могут быть похожи, но в последовательности кадров они различаются.

BatchNorm3D

BatchNorm3D нормализует значения признаков после сверток. Это делает обучение стабильнее, уменьшает риск резких скачков градиентов и помогает корректно использовать pretrained веса. Для небольшого датасета это особенно важно.

ReLU

ReLU зануляет отрицательные значения и пропускает положительные. По смыслу: если признак найден — он проходит дальше; если не найден — он подавляется. Без нелинейности модель не смогла бы учить сложные различия между действиями.

MaxPool3D

MaxPool3D уменьшает размер признаковых карт и оставляет наиболее сильные признаки. Это снижает вычислительную нагрузку и делает модель менее чувствительной к тому, стоит человек чуть левее, правее, ближе или дальше от камеры.

Residual blocks

Residual block — главная идея ResNet. Он содержит несколько Conv3D/BatchNorm/ReLU операций и skip connection: $\text{output} = F(\text{input}) + \text{input}$. Благодаря этому модель учит не всю функцию заново, а поправку к уже найденным признакам.

Это помогает обучать более глубокую сеть. Ранние слои видят простые признаки: контуры и базовое движение. Средние слои собирают движения рук, ног и корпуса. Глубокие слои распознают уже целые паттерны действий: push_ups, squat, run, jump.

Stage	Уровень признаков	Пример для проекта
layer1	простые признаки	контуры тела, изменение силуэта, движение рук/ног
layer2	средние признаки	ходьба, бег, начальные циклические движения
layer3	сложные движения	движение корпуса вниз-вверх, динамика упражнения
layer4	семантика действия	squat, push_ups, run, jump как целые действия

Global Average Pooling и Linear classifier

Global Average Pooling превращает набор feature maps в компактный вектор признаков. После этого Linear classifier переводит этот вектор в 8 чисел — logits по классам проекта. Последний слой оригинальной pretrained модели был заменен на новый Linear слой под 8 классов.

5. Почему выбран transfer learning

Модель не обучалась с нуля. Использован pretrained video backbone R3D-18. Это важно, потому что 82 видео и 716 событий — хороший учебный набор, но для обучения 3D-CNN с нуля этого мало. Обучение с нуля привело бы к сильному переобучению.

Transfer learning позволяет взять уже выученные общие video features: движение, силуэт человека, динамику объектов. Затем модель аккуратно адаптируется под 8 пользовательских классов.

Стратегия обучения

Этап	Что обучается	Зачем
head_warmup	только classifier head	быстро адаптировать выход модели под 8 классов
last_block_finetune	layer4 + classifier head	аккуратно адаптировать высокоуровневые признаки под локальный датасет

Такой staged fine-tuning снижает риск переобучения: ранние слои, отвечающие за универсальные признаки видео, сохраняются, а последние слои подстраиваются под конкретную задачу.

Что использовалось при обучении

- CrossEntropyLoss — стандартная функция потерь для многоклассовой классификации.
- AdamW — оптимизатор с weight decay, помогает регуляризации.
- Cosine learning rate schedule — плавно уменьшает learning rate.
- Balanced sampler — помогает реже встречающимся классам попадать в batch чаще.
- Label smoothing — снижает переуверенность модели.
- Augmentation — повышает устойчивость к небольшим изменениям кадра.
- Temperature scaling — калибрует confidence после обучения.

6. Pipeline регистрации событий

Нейросеть сама по себе классифицирует короткие клипы. Чтобы получить события в длинном видео, используется отдельный pipeline.

Шаг	Что происходит
1. Video reading	видео читается через OpenCV
2. Sliding window	по видео идет окно из 16 кадров
3. Model prediction	модель предсказывает класс и confidence для каждого окна
4. Threshold	низкоуверенные предсказания отбрасываются
5. Smoothing	метки сглаживаются во времени
6. EventRegistry	поток предсказаний превращается в события
7. Export	сохраняются events.json, events.csv, timeline.png, annotated.mp4

EventRegistry

EventRegistry — это важная инженерная часть проекта. Сырые предсказания модели могут шуметь: на границах событий модель иногда переключается между соседними классами. EventRegistry сглаживает поток предсказаний, удаляет слишком короткие события, объединяет одинаковые события через маленький gap и закрывает последнее событие в конце видео.

Boundary refinement

После формирования события применяется уточнение границ. Алгоритм смотрит около start_sec и end_sec и ищет моменты, где модель стабильно предсказывает тот же label с достаточной уверенностью. Это улучшает временную локализацию событий.

7. Подсчет повторений

В проект добавлен счетчик повторений для периодических действий: push_ups, squat, bend и jump. Он не меняет checkpoint модели и не вмешивается в классификацию. Сначала R3D-18 находит действие и его временной интервал, затем отдельный post-processing анализирует движение внутри этого интервала.

Для pose-friendly классов может использоваться MediaPipe Pose. Если pose-модель недоступна, inference не должен падать: счетчик становится unavailable или используется fallback-логика по движению.

Важно честно говорить на защите: счетчик повторений — дополнительный модуль, а не главный критерий качества action recognition. Если счетчик ошибается, это не означает, что модель неправильно нашла событие; это отдельная задача анализа периодического движения.

8. Метрики и результаты финальной модели

Для проекта важнее event-level метрики, чем обычная accuracy. Clip-level val_acc показывает, насколько модель классифицирует короткие клипы. Event-level F1 показывает, насколько вся система правильно находит события и их границы в длинном видео.

Метрика	Значение R3D-18	Интерпретация
Precision	0.8189	доля правильных событий среди найденных
Recall	0.8667	доля найденных событий среди всех реальных
F1	0.8421	баланс между precision и recall
Mean IoU	0.6658	качество совпадения временных границ
Mean latency	1.5105 sec	среднее смещение начала события
TP / FP / FN	104 / 23 / 16	правильные, лишние и пропущенные события

Результаты по классам

Класс	Precision	Recall	F1
bend	0.6429	0.7500	0.6923
jump	0.8667	0.8667	0.8667
other	0.8571	0.8571	0.8571
push_ups	1.0000	1.0000	1.0000

run	0.8824	0.8824	0.8824
squat	1.0000	0.9333	0.9655
stand	0.7241	0.8400	0.7778
walk	0.7143	0.8333	0.7692

Самые сильные классы: push_ups, squat, run и jump. Самые слабые: bend, walk и stand. Это логично: bend может быть похож на переход к другому упражнению, walk часто выглядит как перемещение между действиями, а stand возникает короткими фрагментами между активными действиями.

9. Эксперимент X3D-S

Дополнительно был проведен эксперимент с X3D-S из pytorchvideo. Это более компактная video architecture. Она не стала финальной моделью, но дала важный результат по временной локализации.

Модель	Precision	Recall	F1	Mean IoU	Latency	FP	Размер
R3D-18 final	0.8189	0.8667	0.8421	0.6658	1.5105	23	~127 MB
X3D-S threshold 0.55	0.7591	0.8667	0.8093	0.7355	1.1316	33	~12 MB
X3D-S tuned 0.70	0.7704	0.8667	0.8157	0.7321	1.1573	31	~12 MB

Threshold для X3D-S был подобран честно: на validation split лучшим стал 0.70. Validation F1 = 0.9358, validation mean IoU = 0.7815. После выбора threshold модель была один раз оценена на test.

Итог: R3D-18 остается финальной моделью, потому что дает лучший event-level F1 и меньше false positives. Но X3D-S стабильно лучше по Mean IoU и примерно в 10 раз меньше по размеру checkpoint. Это сильный аргумент для дальнейшей работы над edge/mobile deployment.

10. Почему возможны ошибки

- Короткое окно clip_len=16 дает примерно около секунды контекста; плавные переходы между действиями могут быть сложными.
- Классы bend, walk и stand визуально похожи на переходных фрагментах.
- Класс other слишком широкий: туда входят разные движения, которые не имеют единого паттерна.
- Датасет снят в похожих условиях, поэтому модель может хуже обобщаться на новые ракурсы и других людей.
- Границы действий в разметке субъективны: начало и конец события иногда трудно определить даже человеку.

Честная интерпретация результата

Модель показывает хорошее качество на тестовых видео из того же домена съемки. Это не production-grade система для любых людей и любых условий, но полноценный applied ML pipeline, готовый к расширению данных и дальнейшему улучшению.

11. Что говорить на защите

Короткое описание проекта

В проекте реализован полный pipeline для регистрации событий на видеозаписи: от проверки датасета и обучения 3D-CNN до инференса на длинном видео, сглаживания предсказаний, выделения временных событий, визуализации timeline и демонстрации в Streamlit.

Почему R3D-18

Я выбрала R3D-18, потому что задача связана не только с изображением, но и с движением во времени. 3D-свертки анализируют сразу несколько кадров, поэтому модель видит динамику действия, а не только одну статичную позу.

Почему не обучение с нуля

Датасет ограничен, поэтому обучение 3D-CNN с нуля привело бы к переобучению. Я использовала pretrained backbone и staged fine-tuning: сначала обучалась классификационная голова, затем последний residual block.

Как объяснить метрики

Финальная модель R3D-18 получила event-level $F1 = 0.8421$, precision = 0.8189, recall = 0.8667. Это значит, что модель находит большую часть событий и достаточно хорошо отделяет правильные события от ложных.

Как объяснить ограничения

Прямого leakage между train и test нет, потому что split сделан по исходным видео. Но данные сняты в похожих условиях, поэтому для production-качества нужно добавить больше людей, ракурсов, фонов и отдельный holdout-набор.

12. Итоговая ценность проекта

Главная ценность проекта не только в обученной модели, а в полном воспроизводимом pipeline. Система проверяет данные, обучает video action recognition модель, выполняет sliding-window inference, регистрирует события во времени, строит timeline, экспортирует JSON/CSV, создает annotated video и дополнительно считает повторения для упражнений.

Это делает проект ближе к реальной applied ML-системе, а не просто к notebook с классификацией. Архитектура проекта готова к расширению датасета, переобучению модели, добавлению новых классов и улучшению обобщающей способности.